

预训练之训练技术


赵森栋

优化参数设置


➤ 现有大语言模型的预训练优化设置

模型	批次大小	学习率 (预热 → 峰值 → 衰减)	优化器	精度 类型	权重 衰减	梯度 裁剪
GPT-3	32K → 3.2M	预热 → 6×10^{-5} → 余弦	Adam	FP16	0.1	1.0
OPT	2M	预热 → 1.2×10^{-4} → 手动	AdamW	FP16	0.1	-
PaLM	1M → 4M	1×10^{-2} → 平方根倒数	Adafactor	BF16	lr^2	1.0
BLOOM	4M	预热 → 6×10^{-5} → 余弦	Adam	BF16	0.1	1.0
LLaMA-2	4M	预热 → 1.5×10^{-4} → 余弦	AdamW	-	0.1	1.0
Baichuan-2	-	预热 → 1.5×10^{-4} → 余弦	AdamW	BF16	0.1	0.5
Qwen-1.5	4M	预热 → 3×10^{-4} → 余弦	AdamW	BF16	0.1	1.0
InternLM-2	5M	预热 → 3×10^{-4} → 余弦	AdamW	-	0.1	-
Falcon	预热 → 4M	预热 → 1.25×10^{-4} → 余弦	AdamW	BF16	0.1	0.4
DeepSeek	18M	预热 → 3.2×10^{-4} → 余弦	AdamW	BF16	0.1	1.0
YuLan	4.5M	预热 → 3×10^{-4} → 余弦	Adam	BF16	0.1	1.0
GLM-130B	0.4M → 8.25M	预热 → 8×10^{-5} → 余弦	AdamW	FP16	0.1	1.0

3D 并行训练



将模型复制、数据平均分配
分别计算后合并梯度，统一更新




将模型均分到不同卡，缓解冗余
计算时动态从对应卡读取参数

划线部分不长期存储
需要时动态获取

3D 并行训练


张量并行



将模型参数 W 拆分为 W_1 和 W_2

在两张卡并行计算 XW_i 后拼接得到输出


流水线并行



将连续的层分配到不同卡

依次经过每卡串行计算

需要与梯度累积联合使用，
以达到流水线效果




GPipe: Efficient Training of Giant Neural Networks
using Pipeline Parallelism, NeurIPS 2024

激活重计算

- 激活值是前向传播的结果，需要在反向传播时参与梯度计算

前向传播（激活值）


反向传播（梯度）



- 保存激活值需要占用大量显存

前向传播（激活值）


反向传播（梯度）



- 激活重计算：保留部分激活值，反向传播时重新计算其他激活值

混合精度训练

- 同时使用 32 位浮点数和 16 浮点数计算
- 显存减半、效率翻倍
- DeepSeek-V3 使用 FP8 混合训练，进一步减少密集型计算开销



模型参数量估计

- LLaMA 模型参数量如何计算?
 - Transformer 层数 L
 - 隐含层维度 H
 - 中间状态维度 H'
 - 注意力头数 N
 - 上下文窗口长度 T
 - 词表大小 V

	Llama				Llama 2				Llama 3			
	Feb 2023				Jul 2023				Apr 2024			
# params	7B	13B	33B	65B	7B	13B	34B	70B	8B			70B
# training tokens	1T	1T	1.4T	1.4T	2T	2T	2T	2T	15T			15T
hidden embed dim	4096	5120	6656	8192	4096	5120		8192	4096			8192
# attn heads	32	40	52	64	32	40		64	32			64
# attn layers	32	40	60	80	32	40		80	32			80
attention	MHA	MHA	MHA	MHA	MHA	MHA	GQA	GQA	GQA			GQA
# kv heads	32	40	52	64	32	40		8	8			8
nlp intermediate size	11008	13824	17920	22016	11008	13824		28672	14336			28672
context	2048				4096				8192			
tokenizer	BPE sentencepiece				BPE sentencepiece				BPE tiktoken			
token vocabulary	32000				32000				128256			
fine-tuned models	-				Llama-2-Chat (Jul 2023)...				Llama-3-Instruct (Apr 2024)			

模型参数量估计

➤ 输入词嵌入层

➤ $\mathbf{E} \in \mathbb{R}^{V \times H}$, 参数量 VH

➤ 输出层


➤ $\mathbf{O} = \text{softmax}(\mathbf{Y}\mathbf{W})$, $\mathbf{W} \in \mathbb{R}^{H \times V}$

➤ 参数量 VH

➤ 归一化层 (2L+1层)

➤ $\mathbf{x} = \frac{\mathbf{x}}{\text{RMS}(\mathbf{x})} \cdot \mathbf{y}$, $\mathbf{y} \in \mathbb{R}^H$

➤ 参数量 $(2L + 1)H$



模型参数量估计

➤ 多头注意力层 (L层)

$$Q = XW^Q$$


$$K = XW^K$$

$$V = XW^V$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{D}}\right)V$$

$$\text{MHA} = \text{Concat}(\text{head}_1, \dots, \text{head}_N)W^O$$

➤ $W^Q, W^K, W^V, W^O \in \mathbb{R}^{H \times H}$, 参数量共 $4LH^2$



模型参数量估计

➤ 前馈网络层 (L层)

$$G = XW^G$$


$$U = XW^U$$

$$D = \text{Swish}(G) \odot U$$

$$X = DW^D$$

➤ $W^G, W^U \in \mathbb{R}^{H \times H'}, W^D \in \mathbb{R}^{H' \times H}$

➤ 参数量 $3LHH'$



模型参数量估计

➤ LLaMA的参数量为:

$$\underbrace{2VH}_{\text{输入输出}} + \underbrace{H}_{\text{归一化}} + L \left(\underbrace{4H^2}_{\text{注意力}} + \underbrace{3HH'}_{\text{前馈网络}} + \underbrace{2H}_{\text{归一化}} \right)$$

➤ LLaMA 7B

➤ $V = 32000$, $L = 32$, $H = 4096$, $H' = 11008$

➤ 参数量为6,738,415,616

➤ LLaMA 65B

➤ $V = 32000$, $L = 80$, $H = 8192$, $H' = 22016$

➤ 参数量为65,285,660,672

训练显存估计

- 训练模型需要多少显存?
- 训练时显存占用包括以下三部分
 - 模型参数与优化器的显存占用
 - 激活值的显存占用
 - 其他显存占用

田渊栋等人新作：突破内存瓶颈，让一块4090预训练7B大模型



编辑：陈萍、大盘鸡只用 24G 显存，消费级 GPU 就能搞定大模型了。上...

11 month(s) ago

24GB单卡全量微调Llama 3-8B，仅需添加一行代码



举例来说，当训练一个拥有70亿个参数的模型时，以上参数将占用超过1...

10 month(s) ago

只需单卡RTX 3090，低比特量化训练就能实现LLaMA-3 8B全参微调



例如，即便是相对较小的 7B 规模模型，也可能需要高达 60GB 的 GPU...

9 month(s) ago

LLaMA微调显存需求减半，清华提出4比特优化器



但相比之下，单个 gpu 的显存大小却增长缓慢，这让显存成为了大模型...

2023/9/8

用FP8训练大模型有多香？微软：比BF16快64%，省42%内存



在训练前向和后向传递中全程使用 FP8 格式，极大降低了系统的计算，显...

2023/11/2

650亿参数，8块GPU就能全参数微调：邱锡鹏团队把大模型门槛打下来了




全参数微调的显存使用量和推理一样多，大模型不再只是大型科技公司...

2023/6/20

训练显存估计


➤ 模型参数与优化器占用

- 模型参数量为 P ，模型、梯度、优化器共计需要 $16P$ 比特显存
- 例如 7B 模型需要 $16*7B=112GB$ 显存占用




训练显存估计

- 配合 ZeRO 技术将模型参数与优化器占用分配到每个 GPU
- N 张 GPU，使用 ZeRO-3 每张 GPU 显存占用 $\frac{16P}{N}$



激活值显存估计


➤ 若保存所有激活值，7B 模型会产生 17GB 激活值占用（推导见教材）



➤ Transformer训练常保留每一层的输入作为激活值

➤ 批次大小为B，则需要 $2BTH$ 字节保存每层输入

➤ 还需要 $4BTV$ 字节保存输出层 softmax 输入



其他显存估计

- 代码库内核

- PyTorch 框架占用约 1GB

- ZeRO 实现

- DeepSpeed 占用 1~4GB

- 中间结果

- 计算输出层 softmax 函数时, Transformers 代码库会额外引入 8BTV 字节显存占用

- 显存碎片

- 约 1GB

训练显存估计

➤ 训练时每张GPU显存占用:

$$\underbrace{\frac{16\phi}{N}}_{\text{模型与优化器}} + \underbrace{2LBTH + 12BTV}_{\text{激活值}} + \underbrace{6}_{\text{其他}}$$

➤ 以 2 张 A100 80G 训练 LLaMA 7B 为例 (B=8)

➤ 模型与优化器: 50GB

➤ 激活值: 6.2GB

➤ 其他: 10GB

} 单卡总计 66GB

谢谢