

第 6 章作业 1: 基本算子执行算法 (2026 春)

序号: 10 学号: 2023112451 姓名: 颜雨航

一、填空题

1. 设关系 R 的文件包含 $B(R) = 100,000$ 个页, 缓冲池可用页数 M 为 100。对 R 进行外存归并排序, 初始创建 1000 个归并段, 每个归并段包含 100 个页, 创建初始归并段共执行 200000 次 I/O。一次归并最多同时归并 99 个归并段。若要在一趟归并内完成归并排序, 则缓冲区可用页数 M 至少为 317, 该算法共执行 400000 次 I/O。
2. 设关系 R 的文件包含 $B(R) = 10,000$ 个页, 缓冲池可用页数 M 为 101。对 R 中元组进行去重, 基于哈希的去重算法创建 100 个桶, 每个桶期望包含 100 个页, 创建全部桶共执行 20000 次 I/O。执行该算法所需的缓冲区可用页数 M 至少为 101, 该算法共执行 30000 次 I/O。

二、设计题

3. 给定关系 $R(A, B)$, 设计一种基于排序的分组聚集算法, 完成关系代数操作 $\gamma_{A; \text{count}(B)} \rightarrow C(R)$, 并分析该算法的 I/O 次数, 及所需的最少缓冲池页数 M 。注意: 输出结果所需的 I/O 次数不计入, 输出缓冲区页数不计入。

设 $B(R) = B$, 要计算 $\gamma_{A; \text{count}(B)} \rightarrow C(R)$
先将关系 R 按属性 A 进行外部排序, 每次读入 M 页, 在内存中排序后写出一个初始归并段。
共 $\lceil \frac{B}{M} \rceil$ 个。对其进行多路归并。由于排序后相同 A 值连续出现, 可直接分组计数。
读到相同 A 值计数加 1, 读到新的 A 值开始新的分组。

总 I/O 为 $3B(R)$

若要一趟归并完成, $\lceil \frac{B}{M} \rceil \leq M$

最少缓冲池页数 $M_0 = \lceil \sqrt{B(R)} \rceil$

4. 给定关系 $R(A, B)$, 设计一种基于哈希的分组聚集算法, 完成关系代数操作 $\gamma_{A; \text{count}(B)} \rightarrow C(R)$, 并分析该算法的 I/O 次数, 及所需的最少缓冲池页数 M 。注意: 输出结果所需的 I/O 次数不计入, 输出缓冲区页数不计入。

用哈希函数 $h(A)$ 将关系 R 按 A 划分为若干桶, 相同 A 值一定进入同一桶, 因此可独立进行分组统计。

划分阶段使用 1 页作为输入缓冲, 其余 $M-1$ 页为输出缓冲, 因此可建立 $M-1$ 个桶。

期望大小为 $\frac{B}{M-1}$

第二阶段逐桶读入桶, 在内存中建立哈希表。 $A \rightarrow \text{count}(B)$, 扫描桶中元组, 若 A 已存在, 则计数加 1, 否则新建该分组并置计数为 1。

I/O 次数为 $3B(R)$

$\frac{B}{M-1} \leq M$

$M_0 = \min \{ M \mid M(M-1) \geq B(R) \}$

第 6 章作业 1：基本算子执行算法（2026 春）

序号：_____ 学号：_____ 姓名：_____

一、填空题

1. 设关系 R 的文件包含 $B(R) = 100,000$ 个页，缓冲池可用页数 M 为 100。对 R 进行外存归并排序，初始创建_____个归并段，每个归并段包含_____个页，创建初始归并段共执行_____次 I/O。一次归并最多同时归并_____个归并段。若要在一趟归并内完成归并排序，则缓冲区可用页数 M 至少为_____，该算法共执行_____次 I/O。
2. 设关系 R 的文件包含 $B(R) = 10,000$ 个页，缓冲池可用页数 M 为 101。对 R 中元组进行去重，基于哈希的去重算法创建_____个桶，每个桶期望包含_____个页，创建全部桶共执行_____次 I/O。执行该算法所需的缓冲区可用页数 M 至少为_____，该算法共执行_____次 I/O。

二、设计题

3. 给定关系 $R(A, B)$ ，设计一种基于排序的分组聚集算法，完成关系代数操作 $\gamma_{A; count(B) \rightarrow C}(R)$ ，并分析该算法的 I/O 次数，及所需的最少缓冲池页数 M 。注意：输出结果所需的 I/O 次数不计入，输出缓冲区页数不计入。
4. 给定关系 $R(A, B)$ ，设计一种基于哈希的分组聚集算法，完成关系代数操作 $\gamma_{A; count(B) \rightarrow C}(R)$ ，并分析该算法的 I/O 次数，及所需的最少缓冲池页数 M 。注意：输出结果所需的 I/O 次数不计入，输出缓冲区页数不计入。