



School of Computer Science
and Technology, Harbin
Institute of Technology

神经计算与类脑智能原理



李海峰 教授


类脑智能与神经工程研究中心
计算学部

Email: lihaifeng@hit.edu.cn



2026神经计算




群号: 1091671425



2026年3月30日



- 2) T-C Recognition




- others
 - Parity detection
 - Symmetry detection
 - Plus
 - Negation





• 3) Coding – Data compression

• Identical mapping






思考题

- 在你的研究领域，思考一个可以用MLP解决的问题。
- 完成如下工作：
 - 问题表述
 - 数据整理
 - MLP设计






深度神经网络 DNN

MLP的典型应用：
Identical Mapping vs.
Deep Neural Networks




深度学习 vs. 神经网络

神经网络:




深度学习:





传统模式识别方法

• 传统PR方法的流程




- 良好的特征表达，对最终算法的准确性起了非常关键的作用；
- 识别系统主要的计算和测试工作耗时主要集中在特征提取部分；
- 特征同物理过程紧密相连；
- 特征的样式目前一般都是人工设计的，靠人工提取特征。





深度学习训练过程

AutoEncoder :





深度学习的具体模型及方法


- 1 自动编码器 (AutoEncoder)
 - 稀疏自动编码器 (Sparse AutoEncoder)
 - 降噪自动编码器 (Denoising AutoEncoder)
- 2 卷积神经网络 (CNN)





AutoEncoder的变体

- Sparse AutoEncoder 稀疏自动编码器
 - 加上约束条件：L1的Regularity
 - 约束每一层中的节点中大部分都要为0，只有少数不为0



- input: X code: $h = W^T X$

- loss: $L(X; W) = \|W h - X\|^2 + \lambda \sum_j |h_j|$






卷积神经网络CNN

- CNN: Convolutional Neural Networks
- 特点 —— 权值共享
 - 权值共享网络结构使之更类似于生物神经网络，降低了网络模型的复杂度，减少了权值的数量
 - 使图像可以直接作为网络的输入，避免了传统识别算法中复杂的特征提取和数据重建过程；对平移、比例缩放、倾斜或者其它形式的变形具有高度不变性
 - 成为当前语音分析和图像识别领域的研究热点





- 卷积神经网络的网络结构
- 卷积神经网络是一个多层的神经网络，每层由多个二维平面组成，而每个平面由多个独立神经元组成。




输入图像通过和三个可训练的滤波器和可加偏置进行卷积，卷积后在C1层产生三个特征映射图，然后特征映射图中每组的四个像素再进行求和，加权值，加偏置，得到三个S2层的特征映射图。这些映射图再进过滤波得到C3层。这个层级结构再和S2一样产生S4。最终，这些像素值被光栅化，并连接成一个向量输入到传统的神经网络，得到输出。





CNN

- C层为**特征提取层**，每个神经元的输入与前一层的局部感受野相连，并提取该局部的特征；
- S层是**特征映射层**，网络的每个计算层由多个特征映射组成，每个特征映射为一个平面，平面上所有神经元的权值相等。
- 卷积神经网络中的每一个特征提取层（C-层）都紧跟着一个用来求局部平均与二次提取的计算层（S-层），这种特有的两次特征提取结构使网络在**识别时对输入样本有较高的畸变容忍能力**。






关于参数减少与权值共享


- CNN一个优势在于通过感受野和权值共享减少了神经网络需要训练的参数的个数

LOCALLY CONNECTED NEURAL NET



Ran

CONVOLUTIONAL NET



Ran





- ImageNet




ImageNet 是一个计算机视觉系统识别项目，是目前世界上最大的图像识别数据库。此项目由斯坦福大学李飞飞等教授于 2009 年发起，当时在 CVPR2009 上发表了一篇名为 *ImageNet: A Large-Scale Hierarchical Image Database*^[1] 的论文，之后从 2010 至 2017 年举行了基于 ImageNet 数据集的比赛

[1] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]//2009 IEEE conference on computer vision and pattern recognition. IEEE, 2009: 248-255.





AlexNet



第一次展示出CNN处理大规模
图像数据集时的强大能力





AlexNet

● AlexNet — ILSVRC 2012年冠军

AlexNet^[2] 是一个深度卷积神经网络，由Hinton和他的学生Alex Krizhevsky在2012年设计，并在同年赢得了ImageNet图像识别挑战赛的冠军。

AlexNet的主要创新：

1. 包括使用ReLU作为激活函数，成功解决了Sigmoid函数在深层网络中梯度消失的问题；
2. 在训练时采用Dropout技术，以避免模型过拟合；
3. 在CNN中使用重叠的最大池化（MaxPooling）提高了特征的丰富性；
4. 提出了局部响应归一化（LRN）层，增强了模型的泛化能力；
5. 首次在CNN中使用了GPU进行训练加速。



Ilya Sutskever（左） Alex Krizhevsky（中）
Geoffrey Hinton（右）

[2] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.





AlexNet

● AlexNet — ILSVRC 2012年冠军

AlexNet^[2] 是一个深度卷积神经网络，由Hinton和他的学生Alex Krizhevsky在2012年设计，并在同年赢得了ImageNet图像识别挑战赛的冠军。

AlexNet的主要创新：

1. 包括使用ReLU作为激活函数，成功解决了Sigmoid函数在深层网络中梯度消失的问题；
2. 在训练时采用Dropout技术，以避免模型过拟合；
3. 在CNN中使用重叠的最大池化（MaxPooling）提高了特征的丰富性；
4. 提出了局部响应归一化（LRN）层，增强了模型的泛化能力；
5. 首次在CNN中使用了GPU进行训练加速。



Ilya Sutskever（左） Alex Krizhevsky（中）
Geoffrey Hinton（右）


[2] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.






AlexNet

● AlexNet的网络结构



AlexNet网络结构示意图



8层卷积神经网络，前5层是卷积层，剩下的3层是全连接层。





AlexNet

● AlexNet架构及其关键组件

params	AlexNet	FLOPs
4M	FC 1000	4M
16M	FC 4096 / ReLU	16M
37M	FC 4096 / ReLU	37M
	Max Pool 3x3s2	
442K	Conv 3x3s1, 256 / ReLU	74M
1.3M	Conv 3x3s1, 384 / ReLU	112M
884K	Conv 3x3s1, 384 / ReLU	149M
	Max Pool 3x3s2	
	Local Response Norm	
307K	Conv 5x5s1, 256 / ReLU	223M
	Max Pool 3x3s2	
	Local Response Norm	
35K	Conv 11x11s4, 96 / ReLU	105M

AlexNet的网络结构包含8层变换，包括5层卷积和2层全连接隐藏层，以及1个全连接输出层。


其第一层中的卷积窗口形状是 11×11 ，因为ImageNet图像比MNIST图像大很多，所以需要更大的卷积窗口来捕获物体。





● AlexNet架构及其关键组件

● ReLU



ReLU函数是一个分段线性函数，小于等于0则输出0；大于0的则恒等输出。


反向传播中，ReLU有输出的部分，导数始终为1。而且ReLU会使一部分神经元的输出为0，这样就造成了网络的稀疏性，并且减少了参数的相互依存关系，缓解了过拟合问题的发生。





● AlexNet架构及其关键组件

● Max Pooling



它通过从输入特征图（feature map）的一个小区域中选取最大值来工作，这个小区域称为池化窗口。这个过程在整个输入特征图上以特定的步长滑动进行，从而生成一个尺寸更小、但仍保留了最显著特征的输出特征图。

优势


- 降低过拟合风险
- 减少计算量
- 保留关键特征
- 增加模型的空间不变性
- 提高特征的抽象层次
- 减少对目标位置的敏感度






AlexNet架构及其关键组件

Dropout




(a) Standard Neural Net




(b) After applying dropout.

训练阶段和测试阶段



(a) At training time



(b) At testing time

没有dropout的神经网络:

$$\begin{aligned} z_i^{(l+1)} &= \mathbf{w}_i^{(l+1)} \mathbf{y}^l + b_i^{(l+1)}, \\ y_i^{(l+1)} &= f(z_i^{(l+1)}), \end{aligned}$$

有dropout的神经网络:

$$\begin{aligned} r_j^{(l)} &\sim \text{Bernoulli}(p), \\ \tilde{\mathbf{y}}^{(l)} &= \mathbf{r}^{(l)} * \mathbf{y}^{(l)}, \\ z_i^{(l+1)} &= \mathbf{w}_i^{(l+1)} \tilde{\mathbf{y}}^l + b_i^{(l+1)}, \\ y_i^{(l+1)} &= f(z_i^{(l+1)}). \end{aligned}$$





AlexNet

● AlexNet效果

Model	Top-1 (val, %)	Top-5 (val, %)	Top-5 (test, %)
<i>SIFT + FVs⁶</i>	–	–	26.2
1 CNN	40.7	18.2	–
5 CNNs	38.1	16.4	16.4
1 CNN*	39.0	16.6	–
7 CNNs*	36.7	15.4	15.3

In *italics* are best results achieved by others. Models with an "*" were "pre-trained" to classify the entire ImageNet 2011 Fall release (see Section 7 for details).

AlexNet夺得了2012年ImageNet LSVRC的冠军，且准确率远远超过第二名
(Top5错误率为15.3%，第二名为26.2%)





ResNet

● ResNet——ILSVRC 2015年冠军

ResNet^[3]网络是在2015年由微软实验室中的何凯明等提出，斩获当年ImageNet竞赛中分类任务**第一名**，目标检测**第一名**。获得COCO数据集中目标检测**第一名**，图像分割**第一名**。

Deep Residual Learning for Image Recognition

Kaiming He Xiangyu Zhang Shaoqing Ren Jian Sun
Microsoft Research
{kahe, v-xiangz, v-shren, jiansun}@microsoft.com

Abstract

Deeper neural networks are more difficult to train. We present a residual learning framework to ease the training of networks that are substantially deeper than those used previously. We explicitly reformulate the layers as learning residual functions with reference to the layer inputs, instead of learning unreferenced functions. We provide comprehensive empirical evidence showing that these residual networks are easier to optimize, and can gain accuracy from considerably increased depth. On the ImageNet dataset we




Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer “plain” networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.



[3] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.



School of Computer Science
and Technology, Harbin
Institute of Technology



ResNet

● ResNet的网络结构

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

Table 1. Architectures for ImageNet. Building blocks are shown in brackets (see also Fig. 5), with the numbers of blocks stacked. Down-sampling is performed by conv3_1, conv4_1, and conv5_1 with a stride of 2.







ResNet

● ResNet架构及其关键组件

ResNet-18




ResNet-50





● ResNet架构及其关键组件

● GAP (Global Average Pooling)



全局平均池化（GAP）相比于传统的全连接层具有以下优势：


- 1.降低过拟合：** GAP通过将每个通道的空间信息简化为均值，显著减少了模型参数，这降低了过拟合的风险。
- 2.提升可解释性：** GAP强化了类别与特征图的直接联系，使得每个特征图可以被解释为类别信心图（categories confidence maps），为模型的决策提供直观的可解释性。
- 3.灵活的输入尺寸：** GAP使得网络可以处理不同尺寸的输入图像，因为它不依赖于输入的空间维度，这为图像尺寸的变化提供了灵活性。





ResNet

- ResNet架构及其关键组件
- **BN** (Batch Normalization)



Input : $B = \{x_{1...m}\}; \gamma, \beta$ (parameters to be learned)

Output : $\{y_i = BN_{\gamma, \beta}(x_i)\}$

$$\mu_B \leftarrow \frac{1}{m} \sum_{i=1}^m x_i$$

$$\sigma_B^2 \leftarrow \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$$

$$\tilde{x}_i \leftarrow \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

$$y_i \leftarrow \gamma \tilde{x}_i + \beta$$





● ResNet架构及其关键组件

● BN的训练与推理

训练与推理时BN中的均值、方差分别是什么？

训练时，均值、方差分别是该批次内

数据相应维度的均值与方差；

推理时，均值、方差是基于所有批次

的期望计算所得，公式如下：

$$E[x] \leftarrow E_B[\mu_B]$$

$$Var[x] \leftarrow \frac{m}{m-1} E_B[\sigma_B^2]$$

Input: Network N with trainable parameters Θ ;
subset of activations $\{x^{(k)}\}_{k=1}^K$

Output: Batch-normalized network for inference, N_{BN}^{inf}

- 1: $N_{BN}^{tr} \leftarrow N$ // Training BN network
- 2: **for** $k = 1 \dots K$ **do**
- 3: Add transformation $y^{(k)} = \text{BN}_{\gamma^{(k)}, \beta^{(k)}}(x^{(k)})$ to N_{BN}^{tr} (Alg. 1)
- 4: Modify each layer in N_{BN}^{tr} with input $x^{(k)}$ to take $y^{(k)}$ instead
- 5: **end for**
- 6: Train N_{BN}^{tr} to optimize the parameters $\Theta \cup \{\gamma^{(k)}, \beta^{(k)}\}_{k=1}^K$
- 7: $N_{BN}^{inf} \leftarrow N_{BN}^{tr}$ // Inference BN network with frozen parameters
- 8: **for** $k = 1 \dots K$ **do**
- 9: // For clarity, $x \equiv x^{(k)}, \gamma \equiv \gamma^{(k)}, \mu_B \equiv \mu_B^{(k)}$, etc.
- 10: Process multiple training mini-batches $\mathcal{B}$, each of size m , and average over them:

$$E[x] \leftarrow E_B[\mu_B]$$


$$Var[x] \leftarrow \frac{m}{m-1} E_B[\sigma_B^2]$$
- 11: In N_{BN}^{inf} , replace the transform $y = \text{BN}_{\gamma, \beta}(x)$ with $y = \frac{\gamma}{\sqrt{Var[x] + \epsilon}} \cdot x + \left(\beta - \frac{\gamma E[x]}{\sqrt{Var[x] + \epsilon}}\right)$
- 12: **end for**





ResNet

● ResNet架构及其关键组件





ResNet

● ResNet效果

method	top-5 err. (test)
VGG [41] (ILSVRC'14)	7.32
GoogLeNet [44] (ILSVRC'14)	6.66
VGG [41] (v5)	6.8
PReLU-net [13]	4.94
BN-inception [16]	4.82
ResNet (ILSVRC'15)	3.57

Table 5. Error rates (%) of **ensembles**. The top-5 error is on the





- **深度学习的思想：**
 - 结构：同MLP。
 - 运行：同MLP。
 - 学习：同MLP-EBP（有教师学习）。
 - 特点：
 - 用无教师学习进行权值初始化，之后再继续进行EBP。
 - 不同层的学习方法也可以是不一样的。
 - 各种变体：基于自编码、基于稀疏编码、基于...





本小节结束，谢谢大家！

Thank You !

