

哈爾濱工業大學

《神经计算与类脑智能 原理》课程报告

题目 情感的脑机制及其对情感计算的启示

专业 人工智能

学号 2023112451

姓名 顾雨航

第1章 问题定义

情感是人类智能中最复杂、最难被彻底形式化的部分之一。它既不是单纯的主观体验，也不是外显表情、语音语调或生理信号的简单总和，更不是某个脑区的局部活动所能完全解释的对象。就神经科学而言，所谓“情感的脑机制”，指的是情感如何被诱发、如何在大脑中表征、如何被调节，并最终如何影响知觉、记忆、决策和行为输出的全过程。就人工智能而言，所谓“人工情感”或“情感计算”，则是让机器能够感知、识别、推断、解释甚至适度回应人类情感状态的一类技术路线。二者并不是彼此分离的两个问题，而是“机制研究”与“工程实现”之间的双向映照。

长期以来，公众和部分早期研究常把情感理解为若干固定类别，例如高兴、悲伤、愤怒、恐惧等，并倾向于寻找与某种情绪一一对应的特定脑区。这种思路在经验上虽然直观，但已经越来越难以解释复杂自然情境中的情感现象。人类的情感体验往往具有连续性、混合性、情境依赖性和目标依赖性：同一个外部刺激会因过往经历、当前任务目标、社会关系和语境不同而产生截然不同的情感反应；同一种面部表情也可能由于场景背景差异而被理解为不同的心理状态。由此可见，情感不是一种静态标签，而更接近一种由多层表征、上下文建模和控制过程共同构成的动态系统。

从课程报告的主题出发，本文所讨论的“情感的脑机制”主要包括四个层面。第一，情感的神经环路基础，即情感状态由哪些相互作用的神经系统支撑；第二，情感的表征方式，即大脑究竟以何种形式编码情感信息，是以模态特异方式编码，还是以更抽象、更跨模态的方式编码；第三，情感调节与目标控制，即个体在面对情感刺激时，如何利用前额叶等高级控制网络实现行为选择、抑制和重评；第四，情感与认知、社会情境的耦合，即情感如何嵌入更广义的感知—理解—行动链条之中。围绕这四个问题，近年的高水平研究已经逐步从“局部脑区激活”转向“分布式网络、因果干预与自然情境建模”的研究范式^{[1]-[3]}。

与之对应，本文所讨论的“对人工情感的启示”并不仅仅是指“从脑科学中借几个概念放进模型里”，而是要回答更实质的问题：如果人脑中的情感机制本身就是分布式、动态的、跨模态的，并且受目标控制与上下文约束，那么人工系统是否仍应停留在“输入一句话、输出一个情绪标签”的阶段？如果情感在大脑中同时包含了主观体验、感知线索、行为准备和控制信号，那么人工情感系统是否也应该从单纯识别转向推理、解释、调节与互动？如果上下文既能帮助理解情绪，也可能造成偏差，那么情感计算的模型结构是否需要显式地处理“有益上下文”和“有害偏差”之间的张力？这些问题决定了本文不会把神经科学与人工智能分成两个互不相干的部分，而是强调二者之间的机制映射关系。

因此，本文对主题的界定是：以近五年代表性研究为基础，分析情感在大脑中的神经环路、抽象表征和调节机制，并进一步讨论这些研究如何启发多模态情感识别、情感推理、上下文去偏和可解释人工情感系统的设计。这样一种界定方式既保留了神经计算课程所强调的“脑机制—计算启示”主线，也能够把近年情感计算中出现的大模型、多模态和因果去偏等新趋势纳入一个统一框架中。

第 2 章 研究的目的是与意义

选择“情感的脑机制及其对人工情感与情感计算的启示”作为课程报告主题，首先是因为情感问题本身位于认知神经科学与人工智能的交叉前沿。与视觉分类、语音识别等任务不同，情感处理天然具有更强的主观性和情境性。人在现实生活中并不是先独立感知一个刺激，再独立贴上情绪标签，而是在感知、记忆、期望、目标、社会关系和行动准备的共同作用下形成情感体验。正因如此，情感一直是检验“类人智能”是否真正走向深层理解的重要领域。一个只会统计共现模式、却无法理解情境中情感意义的系统，难以胜任心理陪伴、教育反馈、人机协作、健康辅助等任务。

从神经科学角度看，本主题的研究意义在于推动我们重新理解情感与认知的关系。传统二分法常把“理性”与“情感”看作彼此对立的两个系统，仿佛理性负责计算、情感负责干扰。然而越来越多的研究表明，情感并不是理性的对立面，而是行为选择与适应性控制的重要组成部分。情感会影响注意资源分配、记忆编码、风险评估和目标维持；反过来，前额叶控制过程也会对情感刺激的解释和反应方式施加影响。理解这一点，对于解释真实人类行为至关重要，也直接挑战了将智能系统设计成“纯粹理性优化器”的传统思路。

从人工智能角度看，本主题的研究意义在于为情感计算摆脱“浅层模式匹配”提供理论依据。过去十余年，情感识别系统主要依赖文本情感分类、语音情感识别、面部表情识别等任务范式。这些任务在标准数据集上可以取得较高准确率，但一旦进入自然环境，就会受到语境转移、跨文化差异、个体差异和噪声干扰等问题影响。近年出现的多模态大模型与情感推理模型，虽然提升了系统对复杂情境的处理能力，但也暴露出新的局限：模型可能过度依赖背景语义，错误地把“场景”当作“情绪本身”；也可能只学会数据集中高频的标签关联，而缺乏真正的因果理解^{[4][5]}。因此，脑机制研究能够为模型设计提供一种更稳健的启发，即把情感看成由多源信息、多层表征和控制过程共同形成的结果。

此外，本主题还具有明显的应用价值。第一，在情感陪伴、教育反馈、心理健康辅助等场景中，系统如果只会输出“积极”“消极”等粗粒度标签，就很难做出恰当回应；而如果能够结合上下文、识别不确定性、理解情感强度和目标冲

突，就更可能做出有帮助而不过度冒进的反馈。第二，在自动驾驶、智能座舱、可穿戴设备等应用中，识别驾驶员或使用者的应激、疲劳、挫败与警觉状态，不仅是人机交互问题，也涉及安全与决策支持。第三，在社交媒体分析和公共服务等领域，系统对群体情绪的判断如果存在偏差，就可能放大刻板印象或误导风险评估，因此去偏与解释能力同样重要。

对本报告而言，研究目的并不是穷尽整个情感科学领域，而是通过五篇代表性文献建立一条清晰的分析链条。第一篇综述用于回答“情感为什么必须被理解为分布式神经环路过程”；第二篇因果干预研究用于说明“前额叶目标控制在情感加工中不是附属现象，而是关键机制”；第三篇脑表征研究用于回答“大脑如何在模态特异与抽象表征之间组织情感信息”；第四篇多模态大模型研究对应“人工系统如何把视觉、音频和文本联合起来做情感推理”；第五篇上下文去偏研究对应“情感计算在真实场景中为什么必须控制偏差”。通过这样的安排，报告既能体现选题的系统性，也能避免把文献简单堆砌成孤立摘要。

总体而言，本研究主题的意义可概括为三点：其一，在理论上，推动我们从网络、表征与控制三个层次理解情感；其二，在方法上，促使人工情感系统从单标签识别转向多模态、因果化与可解释推理；其三，在应用上，为构建更稳健、更谨慎、更符合人类社会语境的情感智能系统提供方向。这也是神经计算课程中“从脑机制出发反哺人工系统设计”的典型问题。

第 3 章 代表性的研究工作

3.1 《Neural Circuits for Emotion》：从局部脑区到分布式情感环路

Malezieux、Klein 与 Gogolla 发表在《Annual Review of Neuroscience》的综述文献，是理解本主题最好的总览型入口[1]。这篇文章的关键贡献，不在于提出一种全新的单一理论，而在于系统梳理了跨物种、跨方法、跨层次的研究证据，说明情感应被理解为由多种脑区与身体系统共同参与的功能性状态，而不是由某一“情绪中枢”孤立产生的结果。作者强调，情感状态具有全局协调性、价性、强度、优先性、泛化性和持续性等特征，这些特征表明情感本质上是一种会同时影响感知、行动准备、自主神经、激素水平和认知资源分配的综合性生物状态。

在研究方法上，这篇综述整合了动物行为学、电生理、回路操控、功能磁共振成像和跨物种比较研究。其优点在于，作者没有仅仅用人脑功能成像中“某区激活”的结果来解释情感，而是把神经环路层面的因果操控证据也纳入讨论。例如，在恐惧、奖赏、攻击、育幼和社会联结等不同功能性情感状态中，杏仁核、

下丘脑、中脑导水管周围灰质、腹侧被盖区、伏隔核、岛叶和前额叶等区域都以不同方式参与其中。这里的重要结论不是“任何脑区都重要”，而是“不同情感状态依赖于重叠而非完全独立的网络配置”。这意味着情感的神经基础更像是一个可重组的网络系统，而不是一组彼此分隔的模块。

这篇综述对本文最直接的价值有两点。其一，它为后文讨论“情感不应被简化为单标签分类任务”提供了神经科学基础。如果情感本身就是一个牵涉感知、记忆、动机与行动的分布式系统，那么人工系统只盯着面部表情或句子情感极性，自然会遗漏大量关键信息。其二，它为后文讨论多模态与上下文提供了理论前提。综述反复强调，情感并非脱离环境和身体而独立存在，而是在外部线索、内部状态和行动需求的交互中生成的；这与多模态情感计算中“视觉—音频—文本—上下文”联合建模的工程直觉高度一致。

当然，综述的局限也需要指出。第一，综述性工作擅长搭建全景图，但不一定能对具体争议给出定量裁决。例如，不同情感是否可以被严格区分为离散类别、不同物种之间的情感是否可以一一对应，这些问题在综述中仍然保留了开放性。第二，综述中的很多结论来自实验室任务与特定物种模型，离复杂自然社会场景仍有距离。第三，综述强调分布式网络，虽然有助于摆脱“单区决定论”，但也带来新的困难：当一个功能由多个网络共同参与时，如何在计算上提炼出稳定、可实现的表示框架，并不是自然而然就能完成的任务。

尽管如此，这篇综述仍然为本报告提供了基础逻辑：情感不是脑中的单点事件，而是网络状态；不是静态表征，而是面向行动的动态组织；不是与认知对立，而是深度嵌入适应性行为之中的调节机制。若没有这一层认知，后续关于前额叶控制、抽象情感表征和人工多模态情感推理的讨论就会失去共同坐标。

3.2 《Information-based TMS to mid-lateral prefrontal cortex disrupts action goals during emotional processing》：情感加工中的目标控制与因果证据

如果说综述文献回答的是“情感系统总体上是怎样的”，那么 Lapate 等发表于《Nature Communications》的研究则进一步回答了“情感加工中，前额叶目标控制到底起什么作用”[2]。这篇文章的重要性在于它不是单纯观察相关性，而是结合 fMRI、多变量表征分析和基于信息的经颅磁刺激，直接检验 mid-lateral prefrontal cortex（中外侧前额叶皮层）在情感加工中的因果作用。相较于很多只能证明“这里亮了”的研究，这种带有干预性质的设计更能支撑机制层面的推断。在实验设计上，研究者使用了 Affective Go/No-Go 任务。被试需要面对具有情绪价性的面孔刺激，在不同条件下执行“按键”或“抑制反应”的动作目标。作者首

先在基线阶段通过 fMRI 搜索被试个体化的动作目标表征位置，然后在后续会话中对 mid-LPFC 或控制位点施加抑制性 cTBS，再结合行为表现和脑活动变化进行比较。这样的设计具有两个优点：一是避免了只依赖群体平均脑区坐标而忽略个体差异，二是把“情感线索”与“动作目标”真正放在一个统一任务框架中考察，而不是把它们看成两个互不相关的过程。

该研究的核心发现可以概括为三层。第一，对 mid-LPFC 进行信息导向的 TMS 干预之后，被试在负性线索条件下的目标导向行为受到明显干扰，尤其是在需要抑制反应的条件中表现更差。第二，mid-LPFC 中原本可以被解码的动作目标表征显著减弱，说明这里不仅相关，而且确实承载了对当前行为目标有用的信息。第三，在负性情绪加工期间，mid-LPFC 与前极/内侧前额叶等默认网络相关节点之间的功能耦合下降，提示情感相关内部状态信息与控制网络之间的连接在实现目标导向行为中具有重要作用。

这篇研究对人工情感的启示非常强。很多情感计算系统默认流程是：先识别情绪，再输出结果。然而在人类大脑中，情感加工并非停留在“识别”阶段，而是会立刻与当前任务目标和行动选择耦合。也就是说，情感并不是一个需要单独读出的“标签变量”，而是一个会影响控制策略、抑制需求和行动门控的调制信号。换成工程语言，可以说高水平人工情感系统不应只设一个“emotion classifier”，而应在决策模块中显式引入“情绪—目标—行为”联动机制。例如，面对用户愤怒、焦虑、犹豫或沮丧等状态，系统需要考虑的并不只是情绪类别本身，而是当前最合适的回应目标：是解释、安抚、澄清、等待还是中止高风险操作。

这篇文章也提醒我们，情感与认知控制之间不是简单的“谁抑制谁”。传统印象里，前额叶控制常被描绘为对情绪反应的压制机制。但这项研究表明，前额叶并不是站在情感之外“压住情感”，而是在情感背景中维持与更新目标表征，使行为更加情境适配。换言之，调节并不意味着把情感拿掉，而是让情感输入与行动目标之间形成更合理的映射关系。这一点对于设计对话型 AI、教育辅助系统和心理支持系统尤其重要：真正有帮助的系统不应只是“检测到负面情绪就给安慰话术”，而应理解当前目标结构与情绪状态之间的关系。

当然，这项研究也有边界。首先，任务范式仍然相对受控，所操纵的是面孔价性与动作目标之间的相互作用，与真实社会情境中的复杂语言、关系线索相比仍然较简化。其次，TMS 研究虽然提供了因果证据，但作用范围和时间窗有限，难以完全覆盖自然情感调节的连续过程。最后，该研究聚焦于特定前额叶节点，虽然揭示了其关键作用，但并不意味着其他脑区或更大尺度网络不重要。因此，这篇文献最适合作为“因果控制机制”证据，而不是对全部情感调节过程的穷尽解释。

3.3 《Dissecting abstract, modality-specific and experience-dependent coding of affect in the human brain》：情感表征的抽象性、模态特异性与经验依赖性

如果说第二篇文献回答了情感如何影响目标控制，那么 Lettieri 等发表于《Science Advances》的研究更直接地回答了另一个核心问题：大脑究竟以何种形式表征情感^[3]。情感表征是模态特异的，还是抽象的？视觉、听觉乃至感知经验缺失的个体，其情感编码方式是否相同？这项研究之所以重要，是因为它把情感理解从“在哪儿激活”进一步推进到了“如何编码”，而这正是神经计算与机器表示学习之间最关键的接口。

从研究思路来看，这篇文章不是在高度简化的刺激上做静态判断，而是借助自然电影情境、实时情感评分和功能磁共振数据，比较不同感知条件与不同经验背景下的情感编码方式。研究对象不仅包含典型被试，也纳入了先天盲和先天聋被试，从而使研究者能够更清晰地区分“模态本身的影响”与“发育经验的影响”。这一设计非常有价值，因为在讨论多模态与抽象表征时，最难回答的问题恰恰是：所谓抽象，究竟是来自跨模态共享结构，还是来自语言与概念系统的后期整合？而感知经验差异提供了一个接近自然实验的切入点。

根据论文摘要与可获得的图示信息，这项研究指出，情感实例并非仅由某一种感觉通道决定，而是编码于包含感觉皮层、前额叶和颞叶在内的广泛网络之中。更重要的是，其中一部分区域表现出相对抽象、跨模态甚至跨经验的情感编码特征，例如腹内侧前额叶中更接近类别化、模态独立的情感表示；而另一些区域则更明显地保留了与特定感觉输入或发展经验相关的组织方式。换言之，大脑中的情感表征既不是完全集中于感官系统，也不是完全脱离感官的纯符号表示，而是在“感觉特异—抽象整合”之间形成层级化结构。

这项研究对人工智能的启示极其直接。当前很多情感识别系统面临一个常见争论：到底应该做“模态专用模型”，还是做“统一的跨模态情感空间”？从这篇研究可以得到较为稳妥的答案：两者都需要。因为在人脑中，情感表征本身就同时存在模态特异和抽象共享两个层次。视觉中的表情、音频中的语调、文本中的语义线索，都携带各自独特的信息；但如果系统永远停留在模态内部，就无法形成对情感意义的更高阶整合。因此，更合理的模型设计不是在“单模态”和“统一表示”之间二选一，而是建立层级结构：底层保留模态专长，中层实现跨模态对齐，高层形成可用于推理和决策的抽象情感表示。

这项研究还提供了另一个非常值得重视的启发，即经验与发展历史会塑造情感表征。对人工系统来说，这意味着情感理解不应被视为一种一次性训练好的静

态能力。不同文化、不同年龄、不同使用环境中的个体，对相同刺激的情感解释可能不同；同一用户在长期交互中的表达方式也会发生变化。若机器想逼近更真实的人类情感理解，未来系统就需要具备某种“经验依赖的可塑性”，能够在稳定的抽象情感空间之上，逐步学习用户或群体的表达习惯与语境差异。这一点与标准 benchmark 上追求一次性泛化并不矛盾，反而提示我们应把“长期适配能力”纳入情感系统评估。

这篇研究的局限同样需要看到。首先，虽然自然电影刺激比静态图片更接近真实情境，但仍属于受控刺激，不等于真实社会互动。其次，脑表征研究通常面临模型选择与解释层级的问题：当我们说某一区域编码了“抽象情感”，这一定义本身仍受所使用的特征模型、相似性度量和任务框架影响。最后，将盲、聋被试纳入研究能够揭示经验作用，但样本量与群体差异控制往往更具挑战。因此，这项研究最强的价值在于给出了一幅表征层面的“中间图景”：情感表征不是非黑即白，而是由抽象与感官、共享与经验依赖共同组成。

3.4 《Emotion-LLaMA: Multimodal Emotion Recognition and Reasoning with Instruction Tuning》：从情感识别走向多模态情感推理

前面三篇神经科学文献解决的是“人脑如何处理情感”的问题，而 Cheng 等发表在 NeurIPS 2024 的 Emotion-LLaMA 则代表了当前人工情感系统的一个重要方向：把大语言模型、多模态输入和情感推理结合起来[4]。这篇工作的价值不只在提高某个数据集分数，更在于它清晰体现出情感计算领域正在经历的范式转变——从单一模态、单一步骤的情绪识别，走向多模态信息整合、解释和推理。

Emotion-LLaMA 的基本思路是，将视觉、音频和文本三类信息通过情感相关编码器映射到统一语义空间，再通过指令微调让模型既能进行情绪类别判断，也能给出更细粒度的情感推理。论文中一个很重要的设计，是不把音频仅当作附属模态，而是把说话音色、韵律、停顿等线索视为理解情绪不可或缺的组成部分；同时，模型还利用视觉中面部动作单元、场景上下文以及字幕文本等信息，构建更完整的情感描述。这种处理方式与前文神经科学研究中“情感是多源线索整合结果”的观点形成了很自然的呼应。

从研究贡献上看，这篇论文至少体现了三点趋势。第一，情感识别正在从判别式任务扩展到生成式、解释式任务。模型不再只是回答“这是愤怒还是悲伤”，而是尝试说明支撑判断的视觉、音频和文本依据。第二，多模态情感系统开始显式构造中间表示，例如从视频帧中提取表情描述、从语音中提取语调描述，再融

合成更丰富的情感语义输入。第三，指令微调使模型在情感任务上更接近“可对话的系统”而不是“封闭分类器”，这意味着情感计算正在逐渐与通用智能代理结合。

将这项工作与前面的脑机制研究对照，会发现一个非常有意思的对应关系。脑中的情感处理并不是单通道读取，而是会整合表情、语调、场景意义、记忆和控制目标；Emotion-LLaMA 的设计同样强调多源输入的联合建模。脑中的情感表征既包含感官特征，也包含更高层的抽象意义；Emotion-LLaMA 也不是停留在原始像素或声学特征层面，而是把这些线索转化为可与语言系统对接的语义表示。脑中的情感处理会为后续决策与互动服务；Emotion-LLaMA 则让模型具备了更强的情感解释与响应潜力。从这个意义上说，它并不是“脑启发模型”的直接复制品，但确实在工程上朝着更符合脑机制直觉的方向前进。

不过，这类工作也暴露出当前人工情感的若干问题。第一，多模态并不自动等于真正理解。模型可能把多个模态的信息拼接在一起，却仍然只是做表层相关性匹配。第二，情感数据集本身往往存在标签模糊、文化偏差和情境切分不充分的问题，因此模型的“情感推理”有时更像对训练分布的复述，而未必是真正的可泛化能力。第三，模型虽然能生成情感解释，但解释是否忠实、是否与内部判据一致，仍然需要更严格的检验。第四，在心理支持、教育对话等高敏感场景下，模型若过度自信地解释用户情绪，反而可能造成误导。

因此，Emotion-LLaMA 在本文中的意义不是被视为“终点方案”，而是被视为一座桥梁：它说明人工情感系统已经开始从“识别器”转向“推理器”，开始显式处理跨模态线索，并逐步具备自然语言解释能力。但如果想让这类模型真正具备稳健性，还必须进一步吸收脑机制研究中关于调节、目标控制、经验依赖和上下文去偏的启示。

3.5 《Robust Emotion Recognition in Context Debiasing》：上下文既是资源也是风险

Yang 等发表于 CVPR 2024 的工作，将情感计算中一个非常现实而又长期被低估的问题放到了中心位置：上下文偏差[5]。在真实世界的情感识别任务中，模型经常借助背景、场景、周围人物关系等线索提升判断效果。例如，哭泣的面孔出现在葬礼、医院或拥挤街头时，其情感含义可能不同；但问题在于，模型也很容易把“场景共现”错误当成“情感本体”，从而学到带有偏见的捷径。一旦背景与标签在训练集中高度相关，模型就可能在测试时被错误上下文诱导，做出看似自信却缺乏因果依据的判断。

这篇论文提出的 CLEF 框架，核心思想是在 context-aware emotion

recognition 中显式区分上下文的“有益间接作用”和“有害直接偏差”，并借助反事实推理框架削弱后者影响。通俗地说，作者不是简单地把上下文全部保留或全部移除，而是试图问一个更细的问题：如果保持人物主体不变，只改变上下文线索，模型预测会如何变化？若预测被背景语义过度牵引，就说明模型受到了上下文偏差干扰。通过额外的上下文分支、因果图建模和事实—反事实结果比较，CLEF 尝试从总效应中剥离掉不应被依赖的直接上下文作用。

这项研究之所以与本文主题高度相关，是因为它从工程上回应了一个与神经科学相通的问题：情感理解离不开上下文，但又不能被上下文绑架。前文提到的脑研究表明，情感加工与内部状态、任务目标和感知经验紧密耦合，这意味着情境信息是必要的；但这并不意味着任何背景共现都应被当作有效证据。人类在成熟的情感理解中，能够在很大程度上区分“这个场景通常与某种情绪有关”和“这个具体个体此刻确实处于某种情绪之中”。而很多机器模型缺乏这种区分，于是容易把统计捷径误当作因果线索。CLEF 正是试图让模型向这种更稳健的理解方式靠拢。

从结果层面看，作者表明该框架可以非侵入式地接入多种已有 CAER 模型，并在多个数据集和类别上带来稳定改进。更重要的是，论文通过定性案例展示了去偏前后模型决策的差异：原始模型可能因为背景线索把样本误判为“高兴”“平静”等，而去偏后模型更愿意回到人物主体及其真正相关线索上进行判断。这一点对情感计算实践非常关键，因为真实应用中的风险往往不在于平均指标略低，而在于模型在某些特定社会语境中系统性犯错。

对于人工情感系统而言，这篇论文至少提供了三点启示。第一，情感建模需要区分“有帮助的上下文”和“误导性的上下文”，而不是简单把上下文视为越多越好。第二，情感推理的可靠性不应只看最终准确率，还应考察模型是否依赖了不合理证据。第三，因果与反事实工具值得进入情感计算的主流方法栈，尤其是在高风险应用中，它们有助于提升模型鲁棒性、可解释性与社会可接受性。

当然，这篇工作也并非没有局限。因果图如何设定、哪些路径被视为“偏差”、哪些被视为“有益上下文”，往往依赖任务定义和建模假设；不同文化背景中，某些场景语义本身就与情绪强相关，因此直接剥离可能带来信息损失。换言之，去偏并不是把上下文消灭，而是在统计效率与因果合理性之间取得更精细的平衡。这也是未来情感计算必须继续探索的问题。

3.6 五篇文献的综合比较：从“情感是什么”到“机器如何更合理地处理情感”

将以上五篇文献放在同一条主线上，可以看到一个非常清晰的知识递进。第一篇综述提供了宏观框架，告诉我们情感是分布式神经环路支持的功能状态；第二篇因果干预研究说明情感加工与前额叶目标控制深度耦合；第三篇表征研究进一步揭示情感编码既有模态特异层，也有抽象共享层；第四篇多模态大模型研究展示了人工系统如何把多源情感线索组织为统一推理过程；第五篇因果去偏研究则提醒我们，在使用上下文时必须警惕伪相关与偏差。

如果用一句话概括，这五篇文献共同说明：情感既不是一个孤立脑区，也不是一个孤立标签。它是一个在神经层面上分布式、在表征层面上层级化、在控制层面上目标相关、在工程层面上多模态且容易受偏差影响的复杂过程。因此，真正有前景的人工情感研究不能只做更大的分类器，而应把表征、控制、上下文和解释能力同时纳入设计。

与此同时，这五篇文献也暴露出当前研究的共同难题。神经科学研究往往在可控实验和自然生态有效性之间存在张力；人工智能研究则在性能提升和真实理解之间存在张力。前者知道“人脑可能是怎样工作的”，却难以直接转化为可部署算法；后者可以迅速做出高分模型，却未必清楚模型为什么有效、在什么条件下失效。课程报告的价值恰恰在于把这两类研究放在一起，让脑机制不再只是概念背景，让工程实现也不再只是脱离生物现实的黑箱竞赛。

第 4 章 对人工智能与情感计算的启示

4.1 情感表示不应停留于单标签，而应走向层级化、动态化表示

基于前述脑机制研究，可以得到的第一条启示是：情感表示不应被压缩为单一分类标签。离散情绪标签在研究与工程中当然有其价值，因为它们便于标注、训练和评测；但是如果把它视为情感本体，就会丢失大量关键信息。更符合脑机制直觉的表示方式，应至少包含以下层次：底层保留面部动作、语调变化、语言评价词、场景线索等模态特征；中层表示情感维度、趋势和不确定性；高层则形成可用于推理的抽象状态，例如威胁感、受挫感、期待感、安抚需求、冲突强度等。如此一来，系统才能从“这句话偏消极”进一步走向“当前互动中的主要问题是什么”。

在自然语言处理场景中，这意味着情感分析不能再局限于句级极性判别。对话中的情感往往是跨轮次积累出来的，受到前文、关系角色、任务目标和潜在意

图的共同影响。因此，未来的情感 NLP 更合理的目标，是在多轮语境中追踪情感状态的形成、转移和缓和，而不是仅给每句话打标签。

4.2 多模态不是简单拼接，而应形成结构化的跨模态情感推理

第二条启示是，多模态情感系统需要的不是“把所有模态拼起来”，而是形成结构化的跨模态推理链。人脑对情感的处理并不是把视觉、听觉、语义线索机械叠加，而是根据场景与任务需求，动态评估不同线索的可信度与权重。对于机器而言，视觉中面部表情可能在噪声环境下更可靠，音频中的韵律变化在讽刺、犹豫和情绪强度判断中更关键，文本内容在识别原因归因和态度对象时更重要。系统需要知道“哪一模态为当前判断提供了核心证据”，并在模态冲突时进行权衡。

这对模型架构提出两个要求。一是显式中间表示。像 Emotion-LLaMA 那样，把面部动作描述、场景描述、音频情绪提示和文本内容分别抽取出来，再进行融合，往往比直接让一个黑箱吞下全部原始信号更易于控制和解释。二是支持跨模态校验。一个更加稳健的情感系统应能识别“文本是积极的，但语调和表情并不积极”这类不一致情形，并把这种不一致本身视为重要信号，而不是噪声。

4.3 情感计算应引入“调节”与“目标控制”模块

第三条启示是，情感 AI 不应只有感知模块，还应有与任务目标耦合的调节模块。脑中的前额叶研究提示我们，情感处理并不会在识别完刺激之后自然结束，而是会直接进入控制与行动层面。对话系统、教育系统和智能代理尤其如此：识别出用户“焦虑”并不等于完成任务，真正关键的是系统接下来做什么。是继续追问、放慢节奏、提供解释、转交人工、建议休息，还是只做信息回显？这些都是情感调节问题，而不只是分类问题。

因此，未来的人工情感架构应当把情感状态与系统策略联动建模。例如，可以将目标控制设计为一个上层策略器：当识别到高不确定、高风险或高负向情感状态时，系统自动切换到更保守、更解释性、更少施压的响应策略；在用户积极、专注且任务导向明确时，再进入高效率模式。这样一种设计，比单纯提高识别准确率更接近真正可用的情感智能。

4.4 上下文利用必须与去偏机制配套出现

第四条启示是，任何情感系统只要使用上下文，就必须同步考虑去偏。上下文确实能提升理解能力，但它也可能把模型引向错误捷径。尤其是在图像、视频和社交场景中，背景物体、地点类型、服饰风格甚至群体身份，都可能与训练集标签发生伪相关。模型如果过度依赖这些线索，就会在分布变化时失效，甚至产

生带有社会偏见的判断。

因此，情感计算未来需要把“证据审计”作为标准组件。除了给出情感判断，还应该能回答：这一判断主要由哪些证据支持？如果把背景替换掉，结论会否发生剧烈变化？如果仅保留主体信号，系统还能否维持判断？这种反事实和可解释机制，不仅能提高模型鲁棒性，也能使系统更符合高风险应用中的责任要求。

4.5 情感系统的评测应从“对不对”扩展到“为什么对、何时错、错得是否危险”

第五条启示与评测有关。传统情感识别 benchmark 主要考察最终标签是否正确，但对于真实系统而言，这远远不够。首先，情感本身具有模糊边界，单一标准答案并不总是成立。其次，系统在不同应用中的风险不对称：把“愤怒”误判为“平静”与把“平静”误判为“愤怒”，在后续互动中的后果不同。再次，错误来源本身也很重要：是来自模态缺失、背景误导、文化差异，还是来自模型过度自信？因此，更合理的评测框架应加入不确定性估计、解释一致性、反事实稳定性、跨文化泛化、长期交互表现等指标。只有当情感系统不仅“能答对”，而且“知道自己为什么这样判断，也知道什么时候不应自信”，它才更接近真正可信的人工情感。

第 5 章 未来研究的展望

5.1 从情感识别走向情感状态建模

未来情感计算首先需要完成的转变，是从离散、瞬时、一次性的情绪识别，走向连续、动态、状态化建模。人类的情感具有时间延续性和状态惯性，同一轮表达往往只是更长心理过程中的一个切片。未来系统应能对情感状态的起因、演化方向、波动强度和恢复趋势进行建模，而不是只在某一时刻给出静态判断。

5.2 引入脑启发的层级控制架构

神经科学研究提示我们，情感系统与控制系统并非分离。未来人工情感代理可以考虑采用层级结构：底层做多模态线索感知，中层做情感状态与不确定性估计，高层负责策略控制与响应选择。高层不只根据情感类别决策，而是根据情感—目标耦合状态决定回应方式。这种架构比“情绪识别器 + 模板回复器”的传统形式更接近真实互动需要。

5.3 发展长期个性化适配能力

情感并非纯粹普适模板，它受到个体发展经验、文化背景、人格特质与社会关系历史影响。未来系统应具备安全、可控的长期适配能力，在不侵犯隐私的前提下逐步形成用户特定的表达模型。例如，同样的沉默、反问、夸张表述，在不同个体那里可能有不同含义。能够逐渐学会这种差异，是人工情感真正走向“懂你”而非“像是在猜你”的关键。

5.4 建立面向高风险场景的谨慎原则

情感 AI 的应用往往伴随伦理风险。无论是心理支持、教育评价，还是招聘筛选、公共安全，系统都不应把自身输出当成对个体心理状态的绝对诊断。未来研究应强化谨慎设计：当证据不足时降低自信；当情感判断可能影响重大决策时引入人工复核；在界面上明确告知系统输出的局限性；避免把情感识别结果直接当作性格、能力或道德属性的推断依据。

5.5 推动神经科学与情感计算的双向循环

最后，脑机制研究与情感计算之间应形成真正的双向循环。神经科学为人工系统提供关于表征、控制和上下文利用的启发；而人工模型也可以反过来作为可检验的计算假设，帮助研究者理解人脑在自然情境中的信息整合方式。只有当两者真正互动，而不是彼此借用几个术语，神经计算课程所强调的“脑—机—算”统一视角才能落到实处。

参考文献

- [1] Malezieux M, Klein A S, Gogolla N. Neural circuits for emotion[J]. Annual Review of Neuroscience, 2023, 46: 211-231.
- [2] Lapate R C, Heckner M K, Phan A T, Tambini A, D'Esposito M. Information-based TMS to mid-lateral prefrontal cortex disrupts action goals during emotional processing[J]. Nature Communications, 2024, 15.
- [3] Lettieri G, Handjaras G, Cappello E M, et al. Dissecting abstract, modality-specific and experience-dependent coding of affect in the human brain[J]. Science Advances, 2024, 10(10): eadk6840.

[4] Cheng Z, Cheng Z Q, He J Y, et al. Emotion-LLaMA: Multimodal emotion recognition and reasoning with instruction tuning[C]//Advances in Neural Information Processing Systems 38. 2024.

[5] Yang D, Yang K, Li M, Wang S, Wang S, Zhang L. Robust emotion recognition in context debiasing[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 12447-12457.